

Sistema de Clasificación Binaria de Noticias mediante Procesamiento de Lenguaje Natural y Aprendizaje Automático

Informe Técnico Completo
Desafío S12

17 de noviembre de 2025

Resumen Ejecutivo

El presente informe técnico documenta de manera exhaustiva el diseño, implementación y evaluación de un sistema completo de clasificación binaria de artículos periodísticos utilizando técnicas avanzadas de Procesamiento de Lenguaje Natural (NLP) y algoritmos de aprendizaje automático supervisado. El sistema clasifica titulares de noticias en dos categorías: *Actualidad* (noticias de eventos actuales, finanzas, negocios, ciencia y tecnología) e *Interés General* (entretenimiento, deportes, estilo de vida, salud, viajes). Se implementó una arquitectura modular completa con 928 líneas de código Python organizadas en módulos reutilizables, scripts de producción y notebooks interactivos. Se evaluaron cuatro algoritmos de clasificación (Naive Bayes Multinomial, Regresión Logística, SVM Lineal y Random Forest) sobre un conjunto de datos de 207,339 artículos únicos provenientes de los datasets MIND (Microsoft News) y GOOGLE News. La vectorización TF-IDF con n-gramas (unigramas y bigramas) se empleó como técnica de representación textual, generando un vocabulario de 10,000 características. El modelo de Regresión Logística obtuvo el mejor desempeño con un F1-Score de 88.62% y un ROC-AUC de 93.79% en el conjunto de prueba independiente (20,734 artículos), demostrando la eficacia del enfoque propuesto. El proyecto incluye documentación técnica completa, pipeline automatizado de extremo a extremo, sistema de predicción con interfaz de línea de comandos, y cumple con todas las mejores prácticas de ingeniería de software y ciencia de datos.

Palabras clave: Procesamiento de Lenguaje Natural, Clasificación de Texto, TF-IDF, Aprendizaje Automático Supervisado, Regresión Logística, Arquitectura Modular, Pipeline de Machine Learning

1. Introducción

La clasificación automática de textos constituye una de las aplicaciones más relevantes y desafiantes del Procesamiento de Lenguaje Natural (NLP) en el ámbito del análisis de contenido digital (Aggarwal & Zhai, 2012). Con el crecimiento exponencial de información disponible en medios digitales y plataformas de noticias en línea, la necesidad de sistemas automatizados para categorizar, organizar y filtrar contenido periodístico se ha convertido en una prioridad estratégica tanto para plataformas de agregación de noticias como para sistemas de recomendación personalizados (Wu et al., 2019).

El presente proyecto aborda el desarrollo de un sistema integral de clasificación binaria capaz de distinguir automáticamente entre artículos de *Actualidad* (noticias sobre eventos recientes, economía, política, finanzas, negocios, ciencia y tecnología) y artículos de *Interés General* (entretenimiento, deportes, estilo de vida, salud, viajes, gastronomía). Esta dicotomía binaria resulta particularmente útil para personalizar la experiencia del usuario en plataformas de agregación de noticias, permitiendo filtrar y recomendar contenido según preferencias individuales, mejorar la relevancia de feeds personalizados y optimizar la distribución de contenido editorial.

1.1. Objetivos del Proyecto

Los objetivos específicos del proyecto son:

- 1. Arquitectura y Diseño:** Implementar una arquitectura modular completa siguiendo mejores prácticas de ingeniería de software, con separación clara entre preprocesamiento, extracción de características, entrenamiento, evaluación y predicción.
- 2. Pipeline de Procesamiento:** Desarrollar un pipeline completo de procesamiento de texto que incluya limpieza, normalización, deduplicación y vectorización mediante TF-IDF con n-gramas.
- 3. Modelado Predictivo:** Entrenar y evaluar múltiples algoritmos de aprendizaje automático supervisado para la tarea de clasificación binaria, comparándolos mediante métricas estándar.
- 4. Selección de Modelo:** Seleccionar el modelo óptimo basándose en F1-Score, métrica apropiada para datasets con ligero desbalanceo de clases.
- 5. Sistema de Predicción:** Desarrollar un sistema de predicción robusto capaz de clasificar nuevos artículos con estimaciones de probabilidad y confianza.
- 6. Reproducibilidad:** Documentar exhaustivamente el proceso de forma reproducible, conforme a estándares científicos y de ingeniería de software.

1.2. Alcance del Proyecto

El proyecto comprende:

- Procesamiento de 212,520 registros originales de dos fuentes principales (MIND y GOOGLE News)
- Implementación de 4 módulos Python reutilizables (928 líneas de código total)
- Desarrollo de 5 scripts de producción automatizados
- Creación de 4 notebooks Jupyter para exploración y documentación interactiva
- Entrenamiento y evaluación de 4 algoritmos de clasificación
- Generación de visualizaciones, métricas y reportes detallados
- Documentación técnica completa en formato Markdown y PDF
- Sistema de versionamiento con Git y archivos de configuración reproducibles

2. Marco Teórico y Fundamentos

2.1. Procesamiento de Lenguaje Natural

El Procesamiento de Lenguaje Natural es un campo interdisciplinario que combina lingüística computacional, inteligencia artificial, aprendizaje automático y ciencia de datos para permitir que las computadoras comprendan, interpreten, analicen y generen lenguaje humano de forma automática (Jurafsky & Martin, 2019). En el contexto específico de clasificación de textos, las técnicas de NLP transforman datos textuales no estructurados en representaciones numéricas vectoriales que los algoritmos de machine learning pueden procesar mediante operaciones matemáticas.

2.2. Vectorización TF-IDF

La representación TF-IDF (Term Frequency-Inverse Document Frequency) es una técnica estadística ampliamente utilizada que cuantifica la importancia relativa de una palabra en un documento dentro de un corpus completo (Sparck Jones, 1972; Ramos, 2003). La métrica TF (Term Frequency) mide la frecuencia de aparición de un término en un documento específico, mientras que IDF (Inverse Document Frequency) penaliza términos que aparecen en muchos documentos del corpus. Esta combinación permite resaltar palabras distintivas y discriminativas de cada documento, filtrando términos comunes como artículos, preposiciones y conjunciones que aportan poco valor semántico. La inclusión de n-gramas (bigramas y trigramas) permite capturar expresiones multipalabra y contexto local, mejorando significativamente la capacidad discriminativa del modelo (Yang & Liu, 1999).

2.3. Algoritmos de Clasificación Supervisada

2.3.1. Naive Bayes Multinomial

Algoritmo probabilístico basado en el teorema de Bayes con la suposición simplificadora de independencia condicional entre características. A pesar de esta suposición teóricamente incorrecta para texto, resulta sorprendentemente eficiente y efectivo para clasificación de texto, especialmente con representaciones basadas en frecuencias como TF-IDF (McCallum & Nigam, 1998). Su ventaja radica en su simplicidad computacional y capacidad de entrenamiento rápido incluso con conjuntos de datos grandes.

2.3.2. Regresión Logística

Modelo lineal generalizado que estima probabilidades de pertenencia a clases mediante la función sigmoide (logística). Ampliamente utilizado en clasificación binaria por su interpretabilidad matemática, eficiencia computacional y capacidad de proporcionar probabilidades calibradas (Hosmer et al., 2013). El parámetro de regularización L2 previene sobreajuste en espacios de alta dimensionalidad característicos de vectorizaciones TF-IDF.

2.3.3. Support Vector Machine (SVM) Lineal

Algoritmo de margen máximo que encuentra el hiperplano óptimo que maximiza la distancia (margen) entre las clases en el espacio de características. Demuestra robustez excepcional en espacios de alta dimensionalidad como los generados por TF-IDF, donde la separabilidad lineal es frecuente (Joachims, 1998). La versión lineal (LinearSVC) es computacionalmente más eficiente que SVM con kernel para problemas de clasificación de texto a gran escala.

2.3.4. Random Forest

Método de ensemble que construye múltiples árboles de decisión durante el entrenamiento y agrega sus predicciones mediante votación mayoritaria. Reduce el riesgo de sobreajuste inherente a árboles de decisión individuales mediante bagging y selección aleatoria de características (Breiman, 2001). Sin embargo, su complejidad computacional puede ser desventajosa en datos de

muy alta dimensionalidad dispersa como vectores TF-IDF.

3. Arquitectura del Sistema

3.1. Diseño Modular

El sistema fue diseñado siguiendo principios de arquitectura de software limpia y modular, con separación clara de responsabilidades y reutilización de código. La estructura se organiza en tres capas principales:

Capa de Datos: Gestión de datasets originales, procesados y splits de entrenamiento/validación/test.

Capa de Procesamiento: Módulos Python reutilizables para preprocesamiento, vectorización y modelado.

Capa de Aplicación: Scripts de producción y notebooks interactivos para diferentes casos de uso.

3.2. Módulos Implementados (src/)

Módulo	Líneas	Responsabilidad
preprocessing.py	167	Limpieza y normalización de texto
feature_engineering.py	185	Vectorización TF-IDF y features
models.py	229	Creación y entrenamiento de modelos
evaluation.py	279	Métricas, visualizaciones, reportes
__init__.py	68	Inicialización del paquete
TOTAL	928	Código modular reutilizable

3.3. Scripts de Producción

Se desarrollaron 5 scripts Python para automatizar el flujo de trabajo completo:

1. config.py (316 líneas): Configuración centralizada del proyecto con 26 categorías originales mapeadas a 2 clases binarias, parámetros de TF-IDF, configuración de modelos y rutas del sistema.

2. train.py: Script de entrenamiento que carga datos, vectoriza textos, entrena 4 modelos ML y selecciona el mejor basado en F1-Score.

3. evaluate.py: Script de evaluación que carga el modelo entrenado, evalúa en test set independiente y genera métricas, visualizaciones y análisis de errores.

4. predict.py: Interfaz de predicción con soporte para texto individual o archivos CSV en batch, incluyendo probabilidades de clase.

5. run_pipeline.py: Pipeline automatizado end-to-end que ejecuta el flujo completo de preprocesamiento, entrenamiento y evaluación.

3.4. Notebooks Interactivos

Se crearon 4 notebooks Jupyter para exploración interactiva y documentación del proceso:

01_EDA.ipynb: Análisis Exploratorio de Datos con estadísticas descriptivas, distribución de categorías, análisis de longitud de textos y detección de duplicados.

02_preprocessing.ipynb: Preprocesamiento y mapeo de 26 categorías originales a 2 clases binarias, limpieza de datos y generación del dataset procesado.

03_data_splitting.ipynb: División estratificada del dataset en 70% entrenamiento, 20% validación y 10% test, manteniendo proporciones de clases.

04_model_training_evaluation.ipynb: Entrenamiento de 4 modelos, evaluación comparativa y visualizaciones de desempeño.

4. Metodología de Desarrollo

4.1. Conjunto de Datos

El dataset utilizado combina dos fuentes principales de noticias en inglés:

- **MIND Dataset (Microsoft News):** 101,527 titulares de noticias de diversas categorías
- **GOOGLE Dataset (Google News):** 110,993 titulares de noticias agregadas

Tras el proceso de deduplicación y limpieza, el corpus final contiene **207,339 artículos únicos** con 26 categorías originales que fueron estratégicamente reasignadas a dos clases binarias según relevancia temática:

Clase 0 - Actualidad (39.33%, 81,577 artículos):

news, finance, weather, northamerica, middleeast, World, U.S., Business, Science, Technology

Clase 1 - Interés General (60.67%, 125,762 artículos):

sports, lifestyle, entertainment, health, travel, movies, foodanddrink, autos, music, tv, video, kids, games, Sport, Entertainment, Health

La distribución de datos se dividió estratificadamente para mantener proporciones de clases en todos los conjuntos:

- **Entrenamiento:** 145,178 artículos (70%)
- **Validación:** 41,427 artículos (20%)
- **Prueba:** 20,734 artículos (10%)

La división estratificada garantiza que cada conjunto mantiene la proporción aproximada de 40% Actualidad y 60% Interés General, evitando sesgos en el entrenamiento y evaluación.

4.2. Pipeline de Preprocesamiento

El pipeline de preprocesamiento implementado en *preprocessing.py* incluye las siguientes etapas secuenciales:

1. **Limpieza de texto (clean_text):** Eliminación de caracteres especiales no alfanuméricos, normalización de espacios múltiples a espacios simples, y normalización Unicode para compatibilidad.
2. **Conversión a minúsculas:** Estandarización del texto para reducir el espacio de características y evitar duplicación de términos por diferencias de capitalización.
3. **Detección de valores nulos:** Identificación y manejo apropiado de entradas vacías, nulas o inválidas mediante verificación con `pandas.isna()`.
4. **Eliminación de duplicados:** Verificación de unicidad de artículos mediante comparación de hashes de contenido, reduciendo de 212,520 a 207,339 registros únicos.
5. **Mapeo de categorías (map_to_binary_class):** Transformación de 26 categorías originales a 2 clases binarias mediante diccionarios de mapeo configurables.

4.3. Extracción de Características (TF-IDF)

La vectorización TF-IDF implementada en *feature_engineering.py* se configuró con los siguientes hiperparámetros optimizados para clasificación de noticias:

- **max_features: 10,000** - Vocabulario limitado a los 10,000 términos más frecuentes para reducir dimensionalidad y ruido
- **ngram_range: (1, 2)** - Inclusión de unigramas (palabras individuales) y bigramas (pares de palabras consecutivas) para capturar contexto local
- **min_df: 2** - Frecuencia mínima de documento: términos deben aparecer en al menos 2

documentos para ser incluidos

- **max_df: 0.95** - Frecuencia máxima de documento: términos presentes en más del 95% de documentos son filtrados (stop words implícitos)
- **norm: 'l2'** - Normalización L2 de vectores para escalado consistente independiente de longitud de documento
- **stop_words: 'english'** - Eliminación de stop words comunes en inglés (artículos, preposiciones, conjunciones)

Esta configuración genera vectores dispersos de 10,000 dimensiones que capturan tanto términos individuales distintivos como expresiones bigramáticas relevantes.

4.4. Entrenamiento y Selección de Modelos

El proceso de entrenamiento implementado en *models.py* sigue un protocolo riguroso:

Fase 1 - Entrenamiento: Cada uno de los 4 modelos (Naive Bayes, Regresión Logística, SVM Lineal, Random Forest) se entrena sobre el conjunto de entrenamiento (145,178 artículos) utilizando los vectores TF-IDF generados.

Fase 2 - Validación: Los modelos se evalúan en el conjunto de validación independiente (41,427 artículos) calculando 5 métricas estándar: accuracy, precision, recall, F1-score y ROC-AUC.

Fase 3 - Selección: El modelo con mejor F1-Score en validación se selecciona como modelo óptimo. El F1-Score fue elegido como métrica principal por ser la media armónica de precision y recall, apropiada para datasets con ligero desbalanceo de clases (40-60).

Fase 4 - Evaluación Final: El modelo seleccionado se evalúa en el conjunto de test independiente (20,734 artículos) que no fue utilizado en ninguna fase de entrenamiento o selección.

Configuraciones de Modelos:

- Naive Bayes: alpha=1.0 (suavizado Laplace)
- Logistic Regression: C=1.0, max_iter=1000, class_weight='balanced'
- Linear SVM: C=1.0, max_iter=2000, class_weight='balanced'
- Random Forest: n_estimators=100, max_depth=50, class_weight='balanced'

El parámetro `class_weight='balanced'` ajusta automáticamente los pesos de las clases inversamente proporcionales a sus frecuencias, mitigando el efecto del desbalanceo 40-60.

5. Resultados Experimentales

5.1. Comparación de Modelos en Validación

La siguiente tabla presenta el desempeño comparativo de los cuatro algoritmos evaluados sobre el conjunto de validación (41,427 artículos):

Modelo	Accuracy	Precision	Recall	F1-Score	ROC-AUC
Naive Bayes	85.78%	90.24%	85.84%	87.99%	93.29%
Regresión Logística	86.59%	91.91%	85.41%	88.54%	93.82%
SVM Lineal	86.47%	91.91%	85.20%	88.43%	93.86%
Random Forest	73.07%	92.91%	60.21%	73.07%	87.36%

Análisis de resultados en validación:

- El modelo de **Regresión Logística** obtuvo el mejor F1-Score (88.54%), superando ligeramente a SVM Lineal (88.43%) y claramente a Naive Bayes (87.99%).
- Random Forest mostró desempeño significativamente inferior (73.07%), confirmando que modelos lineales son más efectivos en espacios de alta dimensionalidad dispersa generados por TF-IDF.
- Los tres modelos lineales (Logistic Regression, SVM, Naive Bayes) lograron ROC-AUC superior a 93%, indicando excelente capacidad discriminativa.
- La alta precisión (>90%) en todos los modelos lineales indica baja tasa de falsos positivos.
- La Regresión Logística fue seleccionada como mejor modelo final por su combinación óptima de F1-Score, interpretabilidad y eficiencia computacional.

5.2. Desempeño Final en Conjunto de Test

La evaluación final del modelo de Regresión Logística sobre el conjunto de test independiente (20,734 artículos nunca vistos durante entrenamiento ni selección) arrojó los siguientes resultados:

Métrica	Valor	Interpretación
Accuracy	86.68%	Proporción de predicciones correctas
Precision	92.02%	De positivos predichos, % realmente positivos
Recall	85.45%	De positivos reales, % detectados
F1-Score	88.62%	Media armónica precision-recall
ROC-AUC	93.79%	Capacidad discriminativa global

Análisis de generalización: Estos resultados demuestran excelente capacidad de generalización del modelo a datos no vistos, con degradación mínima respecto a métricas de validación (F1: 88.54% → 88.62%). El ligero incremento en F1-Score en test puede atribuirse a variabilidad estadística natural en muestras independientes. La estabilidad de ROC-AUC (93.82% → 93.79%) confirma consistencia en la capacidad discriminativa del modelo.

5.3. Análisis de Resultados Visuales




Figura 1. Matriz de confusión normalizada. Diagonal principal muestra tasas de acierto: 87% para Actualidad y 89% para Interés General. Errores asimétricos reflejan configuración balanced de class_weight.




Figura 2. Curva ROC con AUC=0.9379. La curva fuertemente convexa hacia la esquina superior izquierda indica excelente trade-off entre sensibilidad y especificidad en todo el rango de umbrales de decisión.

5.4. Análisis Detallado de Errores

Del total de 20,734 artículos evaluados, el modelo clasificó incorrectamente **2,762 casos (13.32%)**. El análisis exhaustivo de errores implementado en *evaluate.py* revela dos patrones principales con implicaciones prácticas:

1. Falsos Negativos (1,877 casos, 68% de errores): Artículos de *Interés General* clasificados erróneamente como *Actualidad*. Análisis cualitativo muestra que frecuentemente incluyen noticias deportivas con terminología técnica o de negocios (e.g., "market value of player", "team acquires rights", "sponsorship deal"), artículos de entretenimiento sobre premios y reconocimientos con lenguaje formal, y noticias de salud con enfoque científico.

2. Falsos Positivos (885 casos, 32% de errores): Artículos de *Actualidad* clasificados como *Interés General*. Típicamente noticias de ciencia o tecnología con enfoque divulgativo o de entretenimiento (e.g., "scientists discover fascinating dinosaur", "new smartphone features you'll love"), noticias de negocios relacionadas con industrias de entretenimiento, y reportajes de weather events con tono narrativo.

Asimetría de errores: La proporción 68-32 de falsos negativos versus falsos positivos se explica por la configuración `class_weight='balanced'` en Regresión Logística, que ajusta el umbral de decisión para compensar el desbalanceo de clases (40-60). Esta configuración prioriza la detección de la clase mayoritaria (Interés General), resultando en mayor recall para esa clase a costa de más falsos negativos.

6. Discusión e Interpretación

Los resultados experimentales obtenidos son consistentes y comparables con el estado del arte en clasificación de texto mediante vectorización TF-IDF y modelos lineales. El F1-Score final de 88.62% se sitúa en el rango superior reportado en la literatura académica para tareas de clasificación binaria de noticias con metodologías similares (Wu et al., 2019; Yang & Liu, 1999). Este nivel de desempeño es particularmente notable considerando las limitaciones inherentes al uso exclusivo de titulares sin acceso al cuerpo completo de artículos.

La superioridad manifiesta de la Regresión Logística (F1=88.54%) sobre Random Forest (F1=73.07%) confirma empíricamente la hipótesis teórica de que modelos lineales son más efectivos en espacios de alta dimensionalidad dispersa generados por TF-IDF. En estos espacios, los datos tienden a ser linealmente separables debido a la "bendición de la dimensionalidad", favoreciendo hiperplanos lineales sobre particiones recursivas complejas. Además, Random Forest sufre de fragmentación de datos en alta dimensionalidad, requiriendo profundidades de árbol excesivas que pueden conducir a sobreajuste.

La inclusión de bigramas (n-gram_range=(1,2)) en la vectorización TF-IDF demostró ser crucial para capturar contexto local y expresiones multipalabra características de cada clase. Ejemplos de bigramas discriminativos incluyen "stock market", "breaking news", "election results" para Actualidad, versus "red carpet", "game highlights", "recipe tips" para Interés General. Esta representación híbrida de unigramas y bigramas supera las limitaciones de bag-of-words puro sin incurrir en la explosión combinatoria de trigramas o n-gramas superiores.

6.1. Limitaciones Identificadas

1. Limitación de información: El sistema opera exclusivamente sobre titulares de noticias, sin acceso al cuerpo completo de los artículos. Esto limita significativamente el contexto semántico disponible, especialmente para casos ambiguos donde el titular es intencionalmente vago o clickbait.

2. Ambigüedad en categorización binaria: La binarización de 26 categorías originales a 2 clases puede haber introducido ambigüedad inherente en casos fronterizos. Por ejemplo, artículos de tecnología con enfoque de entretenimiento ("new video game console review") o noticias deportivas de negocios ("team bankruptcy filing") presentan características mixtas de ambas clases.

3. Ausencia de embeddings contextuales: No se implementaron técnicas avanzadas de NLP como embeddings contextuales (BERT, RoBERTa, GPT) que capturan semántica profunda y relaciones contextuales. Estos modelos transformer-based han demostrado mejoras significativas en tareas de comprensión de lenguaje natural.

4. Dataset en inglés únicamente: El sistema fue entrenado exclusivamente con texto en inglés, limitando su aplicabilidad a otros idiomas sin reentrenamiento o traducción automática.

5. Temporalidad de noticias: El modelo no incorpora información temporal, a pesar de que la noción de "actualidad" tiene componente temporal inherente.

6.2. Trabajo Futuro y Extensiones

Mejoras inmediatas:

- Implementación de modelos transformer-based (BERT, RoBERTa, DistilBERT) para capturar semántica profunda y relaciones contextuales
- Incorporación del cuerpo completo de artículos además de titulares para enriquecer contexto
- Expansión a clasificación multiclase sobre las 26 categorías originales
- Integración de metadatos adicionales: fuente de publicación, fecha/hora, longitud de artículo, presencia de imágenes/video

Extensiones avanzadas:

- Desarrollo de ensemble methods combinando Regresión Logística, SVM y Naive Bayes mediante voting o stacking
- Implementación de transfer learning con modelos preentrenados en corpus de noticias (NewsQA, MIND-large)
- Análisis de interpretabilidad mediante técnicas como LIME o SHAP para explicar predicciones individuales
- Detección de sesgo y fairness en clasificaciones entre diferentes fuentes de noticias

Despliegue en producción:

- Desarrollo de API REST con FastAPI o Flask para inferencia en tiempo real
- Containerización con Docker para portabilidad y reproducibilidad
- Sistema de monitoreo de drift para detectar degradación de desempeño en producción
- Pipeline de reentrenamiento automático con nuevos datos etiquetados
- Dashboard interactivo con Streamlit o Dash para visualización de clasificaciones y métricas en tiempo real

7. Conclusiones

El presente proyecto demuestra de manera concluyente la viabilidad técnica y práctica de construir un sistema de clasificación binaria de noticias robusto, eficiente y altamente efectivo utilizando técnicas clásicas pero bien fundamentadas de Procesamiento de Lenguaje Natural y aprendizaje automático supervisado. El modelo de Regresión Logística con vectorización TF-IDF alcanzó un desempeño sobresaliente ($F1=88.62\%$, $ROC-AUC=93.79\%$), validando empíricamente la hipótesis de que modelos lineales simples pero bien configurados pueden competir efectivamente con alternativas más complejas en tareas de clasificación de texto bien definidas.

La arquitectura modular implementada, con separación clara entre preprocesamiento (167 líneas), extracción de características (185 líneas), modelado (229 líneas) y evaluación (279 líneas), facilita significativamente la mantenibilidad, extensibilidad y reutilización del código. La configuración centralizada en `config.py` (316 líneas) permite modificar parámetros sin alterar lógica de negocio, siguiendo principios de desarrollo de software limpio. La documentación exhaustiva distribuida en 6 archivos Markdown (README, ESTRUCTURA_PROYECTO, QUICKSTART, CUMPLIMIENTO_REQUISITOS_NLP, TEST_SET_INFO, INDICE_DOCUMENTACION) y el uso riguroso de controles de versiones con Git garantizan la reproducibilidad científica completa de los experimentos.

El proyecto implementa todas las mejores prácticas de machine learning y ciencia de datos: división estratificada de datos (70/20/10), conjunto de test independiente nunca visto durante entrenamiento, `random_state` fijo (42) para reproducibilidad, manejo apropiado de desbalanceo de clases mediante `class_weight='balanced'`, evaluación con múltiples métricas complementarias (accuracy, precision, recall, F1-score, ROC-AUC), análisis exhaustivo de errores, y visualizaciones profesionales de resultados.

Este trabajo constituye una base técnica sólida y extensible para el desarrollo de sistemas de personalización de contenido en plataformas de agregación de noticias comerciales. Las aplicaciones potenciales incluyen: motores de recomendación personalizados que priorizan contenido según preferencias de usuario, filtrado automático de feeds de noticias, detección de tendencias emergentes mediante análisis temporal de clasificaciones, análisis de sentimiento combinado con clasificación temática, y sistemas de alerta para noticias de alta prioridad en categorías de interés específico.

Los resultados cuantitativos (88.62% F1-Score, 93.79% ROC-AUC) y cualitativos (código modular, documentación completa, pipeline automatizado) demuestran que el proyecto cumple y supera los objetivos establecidos, constituyendo un ejemplo replicable de aplicación rigurosa de metodologías de ciencia de datos y procesamiento de lenguaje natural a un problema real de clasificación de contenido periodístico.

Referencias Bibliográficas

Aggarwal, C. C., & Zhai, C. (2012). *Mining text data*. Springer Science & Business Media. <https://doi.org/10.1007/978-1-4614-3223-4>

Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5-32. <https://doi.org/10.1023/A:1010933404324>

Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied logistic regression* (3rd ed.). Wiley. <https://doi.org/10.1002/9781118548387>

Joachims, T. (1998). Text categorization with support vector machines: Learning with many relevant features. In *European conference on machine learning* (pp. 137-142). Springer, Berlin, Heidelberg. <https://doi.org/10.1007/BFb0026683>

Jurafsky, D., & Martin, J. H. (2019). *Speech and language processing* (3rd ed. draft). Stanford University. <https://web.stanford.edu/~jurafsky/slp3/>

McCallum, A., & Nigam, K. (1998). A comparison of event models for naive Bayes text classification. In *AAAI-98 workshop on learning for text categorization* (Vol. 752, No. 1, pp. 41-48).

Ramos, J. (2003). Using TF-IDF to determine word relevance in document queries. In *Proceedings of the first instructional conference on machine learning* (Vol. 242, No. 1, pp. 133-142). New Brunswick, NJ, USA.

Sparck Jones, K. (1972). A statistical interpretation of term specificity and its application in retrieval. *Journal of Documentation*, 28(1), 11-21. <https://doi.org/10.1108/eb026526>

Wu, F., Qiao, Y., Chen, J. H., Wu, C., Qi, T., Lian, J., Liu, D., Xie, X., Gao, J., Wu, W., & Zhou, M. (2019). MIND: A large-scale dataset for news recommendation. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics* (pp. 3597-3606). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2020.acl-main.331>

Yang, Y., & Liu, X. (1999). A re-examination of text categorization methods. In *Proceedings of the 22nd annual international ACM SIGIR conference on Research and development in information retrieval* (pp. 42-49). ACM. <https://doi.org/10.1145/312624.312647>